MICROSOFT CERTIFICATION DP-800 · PROJECT DOCUMENTATION · NIVEL 3 AVANZADO

SysDesk AI

Plataforma Inteligente de Soporte TI y Asistente RAG Nativo en SQL Server 2025

AUTOR
Hugo Alcaide Martínez

FECHA
Octubre 2026

CERTIFICACIÓN OBJETIVO
Microsoft Certified: SQL Server Developer Associate (DP-800)

NIVEL DE IMPLEMENTACIÓN
Nivel 3 — Avanzado (Base de Datos Relacional + Seguridad + Optimización + Vector Search DiskANN + Hybrid RRF + RAG Dual con Guardrails y Ollama en Vivo)

170	VECTOR(384)	DiskANN	Llama 3.2
COMPATIBILIDAD	TIPO NATIVO	ÍNDICE VECTORIAL	OLLAMA LOCAL

01 Portada y Resumen Ejecutivo

Cover & Executive Summary

RESUMEN

SysDesk AI es una solución integral de gestión de incidencias de TI (ITSM) y asistencia inteligente para ingenieros de soporte construida íntegramente sobre el motor **Microsoft SQL Server 2025 (nivel de compatibilidad 170)**. El proyecto demuestra cómo unificar en una única plataforma transaccional el diseño relacional normalizado, la seguridad corporativa a nivel de fila y columna, la optimización avanzada de consultas y los flujos modernos de Inteligencia Artificial Generativa (**Vector Search, Búsqueda Híbrida RRF y Retrieval-Augmented Generation con Guardrails Semánticos e inferencia local mediante Ollama Llama 3.2**).

02 Objetivo del Proyecto

Project Objective

OBJ El objetivo principal es diseñar, implementar y validar empíricamente una base de datos de soporte técnico empresarial que reduzca el tiempo medio de diagnóstico y resolución (MTTR) de incidencias críticas, cumpliendo el 100 % de los dominios técnicos de la certificación **DP-800**:

1. Garantizar la integridad de los datos operativos y el cálculo automatizado de acuerdos de nivel de servicio (SLA).
2. Proteger la infraestructura crítica y los datos personales mediante políticas nativas de seguridad (**Dynamic Data Masking** y **Row-Level Security**).
3. Optimizar las colas de atención en tiempo real reduciendo las lecturas lógicas de disco mediante índices compuestos, cubrientes y filtrados.
4. Dotar al motor SQL de capacidades de búsqueda semántica, híbrida y generación aumentada por recuperación (**RAG**) sin depender de bases de datos vectoriales externas, incorporando mecanismos de control de calidad (*Guardrails*) que impidan las alucinaciones del modelo de lenguaje.

03 Caso de Uso de Negocio

Business Use Case

En un departamento de Sistemas dividido en áreas especializadas (*Base de Datos, Redes, Seguridad, Infraestructura, Finanzas y RRHH*), se presentan cuatro retos diarios:

RETO 1

Fricción semántica en las búsquedas: Los usuarios finales reportan incidencias con lenguaje no técnico (*"se queda colgado al sacar las facturas"*), mientras que la Base de Conocimiento (KB) registra causas raíz técnicas (*"Timeout de pasarela RFC en SAP S/4HANA"*).

RETO 2

Riesgo de alucinaciones en asistentes de IA convencionales: Consultar errores técnicos o corporativos en modelos de lenguaje genéricos sin contexto provoca respuestas inventadas o procedimientos no autorizados por la empresa.

RETO 3

Riesgo de exposición de datos sensibles: Un técnico de nivel 1 de *Finanzas* no debe poder consultar ni modificar tickets del área de *Seguridad*, ni visualizar las direcciones IP reales de los servidores centrales ni enviar telemetría interna a nubes públicas.

RETO 4

Latencia en colas de guardia: A medida que el histórico de tickets cerrados crece a miles de registros, las consultas que filtran únicamente los tickets activos urgentes sufren degradación por escaneos completos de tabla.

04 Arquitectura de la Solución

Database-Centric AI Architecture

La arquitectura sigue un modelo **Database-Centric AI**, donde SQL Server 2025 actúa simultáneamente como almacén transaccional, guardián de seguridad y orquestador de IA:

1. **Capa de Acceso y Seguridad (`sec`):** Filtra de forma transparente las filas según el departamento del usuario conectado (`RLS`) y enmascara columnas sensibles (`DDM`).

2. **Capa Transaccional y Analítica (`dbo`):** Gestiona el ciclo de vida de los tickets, almacena telemetría semiestructurada en columnas nativas `JSON` y evalúa el cumplimiento de SLA.

3. **Capa de Búsqueda Inteligente e IA:** Almacena representaciones vectoriales en columnas `VECTOR(384)`, acelera la búsqueda aproximada mediante índices `DISKANN`, fusiona resultados léxicos y semánticos con **RRF**, evalúa umbrales de distancia coseno (*Semantic Guardrails*) y ensambla prompts aumentados tanto para síntesis determinista local como para inferencia en tiempo real contra **Ollama (`llama3.2`)** vía `sp_invoke_external_rest_endpoint`.

05 Modelo de Datos

Data Model · 3NF

El diseño se encuentra en **Tercera Forma Normal (3FN)** e integra cinco entidades:

Entidad	Descripción
`dbo.usuarios`	Identidad, rol (`Admin`, `TecnicoTier1`, `TecnicoTier2`, `UsuarioFinal`) y departamento.
`dbo.sistemas`	Catálogo de activos críticos con su dirección IP (`ip_servidor`), nivel de criticidad y horas objetivo de SLA.
`dbo.kb_articulos`	Artículos técnicos de resolución con su código de error oficial y el vector semántico `contenido_embedding VECTOR(384)`.
`dbo.tickets`	Registro de incidencias con control de severidad (`1` a `4`), estado, validación temporal (`fecha_resolucion >= fecha_apertura`) y telemetría en tipo nativo `metadatos_diagnostico JSON`.
`dbo.auditoria_rag`	Trazabilidad de cada consulta realizada al asistente de IA, registrando la distancia coseno, el contexto JSON inyectado, la respuesta generada y el tiempo de respuesta en milisegundos.

06 Funcionalidades Implementadas (Bloques A – G)

Implemented Features · Blocks A–G

BLOQUE A Desarrollo de Base de Datos

Vistas operativas (`vw_panel_operativo_sla`), funciones escalares (`fn_CalcularHorasResolucion`), triggers *set-based* (`trg_tickets_SellarResolucion`), procedimientos transaccionales (`usp_ResolverTicketConKB`) y consultas avanzadas con `CTE` , funciones de ventana (`DENSE_RANK` , `AVG OVER`), `JSON_VALUE` y expresiones regulares (`REGEXP_LIKE`).

BLOQUE B Desarrollo SQL Asistido por IA

Auditoría crítica documentada en `docs/ai_assisted_sql_audit.md` , corrigiendo el uso de tipos deprecados (`TEXT` / `VARBINARY`) por tipos nativos de SQL Server 2025 (`VECTOR(384)` y `JSON`) y transformando triggers escalares en operaciones orientadas a conjuntos.

BLOQUE C Seguridad

Roles de mínimo privilegio, enmascaramiento dinámico en correos e IPs, y aislamiento por departamento mediante políticas RLS con predicados `FILTER` y `BLOCK` .

BLOQUE D Optimización

Simulación de carga con 2.000 tickets históricos y diseño del índice cubriente filtrado `IX_tickets_Depto_Severidad_Activos` .

BLOQUES E, F Y G IA, Búsqueda Híbrida y RAG Dual

Definición de `EXTERNAL MODEL` , índice `DISKANN` , procedimiento híbrido `usp_BusquedaHibridaKB_RRF` , asistente determinista autónomo `usp_AsistenteRAG_SoporteTI` (`ai/10_rag_copilot_solution.sql`) y asistente conectado en tiempo real a Ollama `usp_AsistenteRAG_SoporteTI_Live` (`ai/11_rag_ollama_live_endpoint.sql`).

07 Consultas y Código Más Importante

Key Queries & Code

Consulta Analítica con `JSON` Nativo, Funciones de Ventana y `REGEXP_LIKE`

consulta_analitica.sql · T-SQL

```sql
WITH MetricasTickets AS (
    SELECT
        t.ticket_id, t.departamento_responsable, t.severidad,
        JSON_VALUE(t.metadatos_diagnostico, '$.host') AS equipo_afectado,
        AVG(dbo.fn_CalcularHorasResolucion(t.fecha_apertura, t.fecha_resolucion))
            OVER (PARTITION BY t.departamento_responsable) AS media_horas_depto,
        DENSE_RANK() OVER (
            PARTITION BY t.departamento_responsable
            ORDER BY t.severidad ASC
        ) AS ranking_prioridad
    FROM dbo.tickets t
    WHERE REGEXP_LIKE(JSON_VALUE(t.metadatos_diagnostico, '$.host'), '^(PC|LAPTOP|SRV)-[A-Z0-9-]+$')
)
SELECT * FROM MetricasTickets;
```

08 Seguridad y Optimización de Consultas

Security & Query Optimization

8.1. Seguridad Multicapa (DDM + RLS)

DDM + RLS

Se implementó la función con enlace a esquema `sec.fn_rls_predicado_departamento` aplicada sobre `dbo.tickets`. Cuando una técnica del área de *Redes* (`lgomez`) ejecuta `SELECT * FROM dbo.tickets`, el motor filtra automáticamente cualquier fila de otros departamentos y bloquea intentos de inserción cruzada (`BLOCK PREDICATE`). Paralelamente, `ip_servidor` se muestra como `10..xxx.xxx.15` salvo para los miembros de `rol_supervisor_ti`.

8.2. Optimización con Índice Compuesto, Cubriente y Filtrado

Para acelerar la consulta de tickets pendientes urgentes (`WHERE estado IN ('Abierto', 'En Proceso') AND severidad <= 2`):

IX_tickets_Depto_Severidad_Activos.sql · T-SQL

```sql
CREATE NONCLUSTERED INDEX IX_tickets_Depto_Severidad_Activos
ON dbo.tickets (departamento_responsable ASC, severidad ASC, fecha_apertura DESC)
INCLUDE (titulo, sistema_id, tecnico_asignado_id, estado)
WHERE estado IN ('Abierto', 'En Proceso');
```

RESULTADO MEDIDO

El plan de ejecución pasó de un `Clustered Index Scan` sobre toda la tabla a un **`Index Seek`** directo sobre el 15 % de registros activos, reduciendo las lecturas lógicas en un 98 % (de 157 páginas a 3 páginas) y eliminando los operadores *Key Lookup* y *Sort*.

09 Funcionamiento de la Capa de IA

Vectors, RRF, Guardrails & RAG

1. **Indexación Vectorial DiskANN (`ai/08_vector_embeddings_and_diskann.sql`):** Cada artículo de `dbo.kb_articulos` cuenta con un vector normalizado en `contenido_embedding VECTOR(384)` indexado con `CREATE VECTOR INDEX ... WITH (METRIC = 'cosine', TYPE = 'DISKANN')`.

2. **Reciprocal Rank Fusion (`ai/09_intelligent_hybrid_search.sql`):** En `dbo.usp_BusquedaHibridaKB_RRF`, el motor combina la posición léxica (`rank_lexico`) y la posición semántica (`rank_vectorial`) aplicando:

   FÓRMULA RRF

   $$RRF = 1 / (60 + rank_{lex}) + 1 / (60 + rank_{vec})$$

   Esto garantiza máxima precisión tanto cuando el usuario escribe un código exacto (`ERR-SQL-18456`) como cuando describe síntomas en lenguaje coloquial.

3. **Pipeline RAG Dual y Guardrail Semántico (`ai/10_rag_copilot_solution.sql` y `ai/11_rag_ollama_live_endpoint.sql`):**
   - *Retrieval:* Extrae la descripción y la telemetría JSON del ticket, calcula su vector y recupera los 3 artículos más cercanos formateados mediante `FOR JSON PATH`.
   - *Guardrail Semántico Anti-Alucinaciones (`@UmbralDistanciaMax = 0.25`):* Durante las pruebas empíricas con el modelo local `llama3.2` (3B) en consola, se verificó que al consultar códigos de error ausentes en la Base de Conocimiento (por ejemplo, `0x8024402F`), un LLM pequeño sin contexto sufre alucinaciones probabilísticas e inventa causas irrelevantes (como fallos de disquete, tarjeta gráfica o Kubernetes). Para blindar el sistema, ambos procedimientos evalúan la distancia coseno antes de generar la respuesta: si `VECTOR_DISTANCE > @UmbralDistanciaMax` , SQL Server bloquea la invocación al LLM y emite automáticamente una orden de escalado a Ingeniería de Nivel 2.
   - *Augmentation:* Construye el payload con `JSON_OBJECT` y `JSON_ARRAY` imponiendo reglas estrictas de *grounding* para citar el código oficial de la KB.
   - *Generation & Audit:* Ofrece dos modalidades separadas y limpias: síntesis determinista instantánea en SSMS (`dbo.usp_AsistenteRAG_SoporteTI`) e invocación HTTP POST en tiempo real a Ollama Llama 3.2 (`dbo.usp_AsistenteRAG_SoporteTI_Live`), registrando toda la telemetría de ejecución en `dbo.auditoria_rag`.

4. **Métrica de Rendimiento y Protección Anti-Alucinaciones**
   - **Inferencia con LLM en hardware local (Intel i5, 16 GB RAM):** Latencia media de generación de tokens: ~34.800 ms.
   - **Filtrado previo por Guardrail Semántico (In-Database):** Decisión y corte en 11 ms, reduciendo un 99.9 % el tiempo de respuesta y el consumo de CPU cuando el problema carece de soporte documentado en la KB.

10 Capturas de Resultados y Evidencias

Results & Evidence · SSMS 22 · Windows 11

10.1 T-SQL Avanzado · JSON + REGEXP_LIKE + Window Functions (extracto: primeras filas)

EVIDENCIA VERIFICADA

	ticket_id	departamento_responsable	titulo	equipo_afectado	sistema_operativo	horas_resolucion	media_horas_depto	ranking_prioridad_depto
1	2985	BaseDeDatos	Incidencia operativa registrada en lote histórico #1980	PC-CORP-1980	Windows 11	3960.40	400.85	1
2	2925	BaseDeDatos	Incidencia operativa registrada en lote histórico #1920	PC-CORP-1920	Windows 11	3840.40	400.85	2
3	2865	BaseDeDatos	Incidencia operativa registrada en lote histórico #1860	PC-CORP-1860	Windows 11	3720.40	400.85	3
4	2805	BaseDeDatos	Incidencia operativa registrada en lote histórico #1800	PC-CORP-1800	Windows 11	3600.40	400.85	4

10.2 Seguridad RLS y DDM · Contraste Admin vs Técnico

EVIDENCIA VERIFICADA

halcaide · Supervisor TI (Admin)

	UsuarioConectado	RolActivo
1	halcaide	Supervisor TI (Admin)

	usuario_id	username	email	rol	departamento
1	1	halcaide	hugo.alcaide@sysdesk.corp	Admin	Infraestructura
2	2	cmartinez	carlos.martinez@sysdesk.corp	TecnicoTier2	BaseDeDatos
3	3	lgomez	laura.gomez@sysdesk.corp	TecnicoTier1	Redes
4	4	dfernandez	david.fernandez@sysdesk.corp	TecnicoTier2	Seguridad
5	5	asanz	ana.sanz@sysdesk.corp	TecnicoTier1	Finanzas

	sistema_id	codigo_sistema	nombre_sistema	ip_servidor
1	1	SYS-SQL-01	Clúster Microsoft SQL Server 2025 Producción	10.20.10.15
2	2	SYS-NET-01	Concentrador VPN Corporativa FortiGate	10.20.1.254
3	3	SYS-SEC-01	Controlador de Dominio Active Directory / Entra ID	10.20.5.10
4	4	SYS-FIN-01	ERP Financiero SAP S/4HANA	10.20.30.50
5	5	SYS-INF-01	Granja de Servidores Kubernetes On-Premise	10.20.40....
6	6	SYS-RRHH-01	Portal del Empleado y Nóminas Workday	10.20.60.22

	departamento_responsable	TotalTicketsVisibles
1	BaseDeDatos	335
2	Finanzas	334
3	Infraestructura	334
4	Redes	335
5	RRHH	333
6	Seguridad	335

lgomez · Técnico Soporte Tier 1 (Redes)

	UsuarioConectado	RolActivo
1	lgomez	Técnico Soporte Tier 1 (Redes)

	usuario_id	username	email	rol	departamento
1	1	halcaide	hXXX@XXXX.com	Admin	Infraestructura
2	2	cmartinez	cXXX@XXXX.com	TecnicoTier2	BaseDeDatos
3	3	lgomez	lXXX@XXXX.com	TecnicoTier1	Redes
4	4	dfernan...	dXXX@XXXX.com	TecnicoTier2	Seguridad
5	5	asanz	aXXX@XXXX.com	TecnicoTier1	Finanzas

	sistema_id	codigo_sistema	nombre_sistema	ip_servidor
1	1	SYS-SQL-01	Clúster Microsoft SQL Server 2025 Producción	10..xxx.xxx.15
2	2	SYS-NET-01	Concentrador VPN Corporativa FortiGate	10..xxx.xxx.54
3	3	SYS-SEC-01	Controlador de Dominio Active Directory / Ent...	10..xxx.xxx.10
4	4	SYS-FIN-01	ERP Financiero SAP S/4HANA	10..xxx.xxx.50
5	5	SYS-INF-01	Granja de Servidores Kubernetes On-Premise	10..xxx.xxx.00
6	6	SYS-RRHH-01	Portal del Empleado y Nóminas Workday	10..xxx.xxx.22

	departamento_responsable	TotalTicketsVisibles
1	Redes	335

	CodigoError	MensajeSeguridadRLS
1	33504	La operación intentada falló debido a que el obj...

10.3 Optimización de Consultas · Tickets activos urgentes (extracto: primeras filas)

EVIDENCIA VERIFICADA

	ticket_id	departamento_responsable	severidad	estado	fecha_apertura	titulo	sistema_id	tecnico_asignado_id
1	1065	BaseDeDatos	1	Abierto	2026-10-22 19:16:12	Incidencia operativa registrada en lote histór...	1	1
2	1125	BaseDeDatos	1	Abierto	2026-10-17 19:16:12	Incidencia operativa registrada en lote histór...	1	1
3	1185	BaseDeDatos	1	Abierto	2026-10-12 19:16:12	Incidencia operativa registrada en lote histór...	1	1
4	1245	BaseDeDatos	1	Abierto	2026-10-07 19:16:12	Incidencia operativa registrada en lote histór...	1	1

10.4 Búsqueda Híbrida RRF sobre la Base de Conocimiento

EVIDENCIA VERIFICADA

	MetodoBusqueda	codigo_error	titulo	nombre_sistema	DistanciaCoseno
1	Búsqueda Semántica Vectorial	ERR-NET-VPN809	Fallo de conexión VPN IPSec por bloqueo de puertos UDP 500 y 4500	Concentrador VPN Corporativa FortiGate	0.00000
2	Búsqueda Semántica Vectorial	ERR-SEC-AD4740	Bloqueo recurrente de cuenta de dominio por credenciales cacheadas tras cambio de clave	Controlador de Dominio Active Directory / Entra ID	0.86603
3	Búsqueda Semántica Vectorial	ERR-FIN-SAP500	Timeout de pasarela RFC al exportar el balance trimestral a Excel	ERP Financiero SAP S/4HANA	0.86877

	codigo_error	titulo	nombre_sistema	rank_lexico	rank_vectorial	distancia_coseno	rrf_score
1	ERR-SEC-AD4740	Bloqueo recurrente de cuenta de dominio por cred...	Controlador de Dominio Active Directory / Entra ID	1	1	0.00015	0.032787
2	ERR-NET-VPN809	Fallo de conexión VPN IPSec por bloqueo de puert...	Concentrador VPN Corporativa FortiGate	NULL	2	0.87375	0.016129
3	ERR-FIN-SAP500	Timeout de pasarela RFC al exportar el balance tri...	ERP Financiero SAP S/4HANA	NULL	3	0.87814	0.015873

	codigo_error	titulo	nombre_sistema	rank_lexico	rank_vectorial	distancia_coseno	rrf_score
1	ERR-INF-OOM137	Reinicio abrupto de contenedor con código Exit 13...	Granja de Servidores Kubernetes On-Premise	1	1	0.00019	0.032787
2	ERR-SEC-AD4740	Bloqueo recurrente de cuenta de dominio por cred...	Controlador de Dominio Active Directory / Entra ID	NULL	2	0.86279	0.016129
3	ERR-NET-VPN809	Fallo de conexión VPN IPSec por bloqueo de puert...	Concentrador VPN Corporativa FortiGate	NULL	3	0.86301	0.015873

10.5 Asistente RAG · Diagnóstico y Registro de Auditoría

EVIDENCIA VERIFICADA

	TicketAnalizado	ArticuloKB_Aplicable	DistanciaCoseno	LatenciaMs	RespuestaAsistenteRAG	PromptAumentadoJSON
1	1002	ERR-SEC-AD4740	0.00010	33	[DIAGNÓSTICO FUNDAMENTADO EN KB: ERR-SEC-AD474...	{"model":"llama3.2","messages":[{"role":"system...

	TicketAnalizado	ArticuloKB_Aplicable	DistanciaCoseno	LatenciaMs	RespuestaAsistenteRAG	PromptAumentadoJSON
1	1003	ERR-FIN-SAP500	0.24952	7	[DIAGNÓSTICO FUNDAMENTADO EN KB: ERR-FIN-SAP500...	{"model":"llama3.2","messages":[{"role":"system...

	TicketAnalizado	ArticuloKB_Aplicable	DistanciaCoseno	LatenciaMs	RespuestaAsistenteRAG	PromptAumentadoJSON
1	1000	ERR-SQL-18456	0.00001	6	[DIAGNÓSTICO FUNDAMENTADO EN KB: ERR-SQL-18456 – ...	{"model":"llama3.2","messages":[{"role":"system...

	auditoria_id	tecnico_consulta	kb_utilizado	distancia_coseno	tiempo_respuesta_ms	respuesta_llm
1	3	halcaide	ERR-SQL-18456	0.00001	6	[DIAGNÓSTICO FUNDAMENTADO EN KB: ERR-SQL-18456 – ...
2	2	halcaide	ERR-FIN-SAP500	0.24952	7	[DIAGNÓSTICO FUNDAMENTADO EN KB: ERR-FIN-SAP500 ...
3	1	halcaide	ERR-SEC-AD47...	0.00010	33	[DIAGNÓSTICO FUNDAMENTADO EN KB: ERR-SEC-AD4740 ...

10.6 Guardrail Semántico · Bloqueo de llamada a Ollama en 11 ms

EVIDENCIA VERIFICADA

	TicketAnalizado	ControlGuardrail	ArticuloRecuperadoKB	DistanciaCoseno	LatenciaMilisegundos	RespuestaGeneradaPorOllama
1	3009	BLOQUEADO_SIN_KB (Ollama No Invocado)	NO-DOCUMENTADO	0.36962	11	AVISO DE SEGURIDAD RAG: La incidencia presenta u...

11 Problemas Encontrados y Soluciones Aplicadas

Pitfalls & Fixes

1. `MSG 42274` **Deprecación del parámetro `TOP_N` en `VECTOR_SEARCH`:** Las versiones actualizadas del motor vectorial en SQL Server 2025 devuelven el error `Msg 42274` si se especifica `TOP_N` dentro de `VECTOR_SEARCH`. Se estandarizó el uso de `SELECT TOP (k)` junto con `ORDER BY VECTOR_DISTANCE(...) ASC`.

2. `THROW` **Requisito de punto y coma previo a `THROW` en T-SQL:** El analizador sintáctico interpreta `BEGIN THROW` como una sentencia incompleta si no se precede de punto y coma; se aplicó `;THROW` en todos los bloques de validación.

3. `ERROR 8116` **Inspección de metadatos vectoriales sin `VECTORPROPERTY` ni agregaciones escalares:** Funciones como `MAX()` o `VECTORPROPERTY` no admiten el tipo `VECTOR(384)` como argumento directo (error 8116). La verificación de dimensiones e indexación se implementó consultando las vistas de catálogo `sys.columns` (validando los 1.544 bytes de almacenamiento para 384 dimensiones `FLOAT32`) y `sys.indexes` (comprobando el índice `VECTOR` / `DISKANN`).

4. `31639 · HTTP 403` **Restricciones de protocolo HTTPS, error 31639 y bloqueo HTTP 403 (DNS Rebinding) al conectar SQL Server con Ollama (`ai/11_rag_ollama_live_endpoint.sql`):**
   - El procedimiento `sp_invoke_external_rest_endpoint` venía deshabilitado por defecto en la instancia y requirió activar `external rest endpoint enabled = 1` mediante `sp_configure`.
   - SQL Server prohíbe incluir la cabecera `"Content-Type"` dentro del `SECRET` de un `DATABASE SCOPED CREDENTIAL` (Mensaje de error 31639), dado que el motor la inyecta de forma nativa al enviar un `@payload` JSON; se resolvió prescindiendo de la credencial explícita para el endpoint local.
   - Dado que SQL Server exige endpoints `HTTPS` con certificados TLS de confianza pública, se expuso el puerto `11434` de Ollama mediante **Cloudflare Quick Tunnels (`cloudflared`)**. Inicialmente, Ollama rechazaba las peticiones con `HTTP 403 Forbidden` al recibir la cabecera `Host` externa del túnel. Se solucionó iniciando Ollama con `$env:OLLAMA_ORIGINS="*"` y ejecutando el túnel con el modificador `--http-host-header localhost`.

5. `ERROR 31629` **Superación del tiempo de espera por defecto (Error 31629) durante la inferencia LLM sobre CPU:** Al ejecutar `llama3.2` (3B parámetros, cuantización `Q4_K_M`) sobre CPU (Intel Core i5-1335U con 16 GB de RAM), el procesamiento del prompt aumentado (562 tokens) y la generación de la respuesta a ~11,5 tokens/segundo requiere entre 32 y 45 segundos, superando el timeout predeterminado de 30 segundos de `sp_invoke_external_rest_endpoint`. Se solucionó parametrizando `@timeout = 120` en la llamada REST.

12 Conclusiones

Conclusions

CONCLUSIÓN

SysDesk AI demuestra que **SQL Server 2025** permite construir aplicaciones empresariales de Inteligencia Artificial de principio a fin sin fragmentar la arquitectura de datos. La combinación de seguridad granular (`RLS` / `DDM`), indexación selectiva, búsqueda vectorial e híbrida nativa (`VECTOR` + `DiskANN` + `RRF`) y un pipeline **RAG con Guardrails Semánticos** —tanto en modo determinista autónomo como conectado en tiempo real a un modelo local **Llama 3.2 en Ollama**— elimina las alucinaciones en soporte técnico, garantiza la soberanía del dato corporativo y ofrece trazabilidad completa en milisegundos.

Hugo Alcaide Martínez
Autor · Proyecto SysDesk AI

Octubre 2026
Fecha · Microsoft DP-800