

SysDesk AI

Propuesta de Solución Inteligente de Soporte Técnico, Búsqueda Semántica y Asistencia RAG sobre Microsoft SQL Server 2025

Autor	Hugo Alcaide Martínez
Documento	Project Proposal & Design Document
Entorno	Microsoft SQL Server 2025 (Compatibilidad 170) · SSMS 22 · Modelos locales de IA (Ollama)
Certificación	Microsoft DP-800: SQL AI Developer Associate
Fecha	Octubre 2026

01 · RESUMEN EJECUTIVO

Justificación y objetivos del proyecto

Los departamentos de soporte de tecnologías de la información (ITSM) se enfrentan a la saturación por incidencias repetitivas, a tiempos de diagnóstico prolongados y a la pérdida silenciosa de conocimiento técnico. Los buscadores clásicos dependen de la coincidencia literal de palabras clave y no logran asociar el lenguaje coloquial del usuario con la documentación oficial, lo que genera duplicidad de esfuerzos y resoluciones inconsistentes.

Se propone **SysDesk AI**, una solución que transformará la base de datos corporativa en un motor activo de búsqueda semántica y recuperación de conocimiento, combinando **Microsoft SQL Server 2025** con inteligencia artificial ejecutada íntegramente en local.

Objetivos principales

- Comprensión conceptual:** el sistema buscará por el significado de la incidencia y no por palabras aisladas.
- Generación asistida verificada (RAG):** las respuestas se redactarán con un modelo de lenguaje anclado a manuales internos aprobados, con abstención explícita cuando no exista documentación.
- Seguridad y privacidad por diseño:** los datos sensibles se protegerán en el motor y no se transferirán a nubes públicas.
- Rendimiento sostenible:** los accesos críticos se resolverán con índices específicos en lugar de escaneos de tabla.

Alcance: prototipo funcional y reproducible, con repositorio público, memoria técnica de 5 a 10 páginas y presentación ejecutiva de 5 a 8 minutos, alineado con las competencias evaluadas en DP-800.

Diagnóstico operativo del entorno ITSM

A medida que las organizaciones crecen, el volumen de manuales, procedimientos y registros históricos resulta inabarcable para los operadores. La propuesta contrasta el modelo actual con el estado objetivo.

Escenario tradicional (ANTES) frente a solución propuesta (DESPUÉS)

ANTES · Rigidez léxica. "La pantalla se queda bloqueada al autenticarme" no coincide con "Excepción de login 18456"; la búsqueda devuelve cero resultados.
DESPUÉS · Búsqueda semántica. El motor comparará conceptos en un espacio vectorial y entenderá que ambas expresiones describen el mismo problema.
ANTES · Exposición de datos. Todos los técnicos ven IPs internas, correos y credenciales temporales.
DESPUÉS · Dynamic Data Masking. Los datos se ocultarán según el rol sin alterar el almacenamiento.
ANTES · Shadow AI. Los operadores pegan errores internos en IAs públicas.
DESPUÉS · RAG local. La respuesta la sintetizará un modelo en el servidor propio con documentación aprobada.
ANTES · Sin segmentación. Acceso a incidencias de finanzas, RRHH y ciberseguridad.
DESPUÉS · Row-Level Security. Cada técnico verá solo los tickets de su especialidad; los supervisores, la visión global.
ANTES · Degradación. Decenas de miles de tickets provocan table scans que saturan la memoria.
DESPUÉS · Index Seek. Índices específicos resolverán los reportes críticos en milisegundos.

Matriz de impacto operativo

Variable	Soporte tradicional	SysDesk AI
Criterio de búsqueda	Coincidencia exacta (LIKE)	Similitud semántica
Lenguaje coloquial	Tolerancia nula	Interpreta sinónimos, descripciones y códigos
Redacción de solución	Lectura manual	Resumen asistido en segundos
Soberanía y coste de IA	Cloud, riesgo de fuga	100% local, coste recurrente cero
Seguridad	Delegada a la interfaz	Integrada en el motor
Rendimiento	Escaneo secuencial	Búsqueda por índices


KPIs de negocio esperados

- MTTR:** reducción sustancial del tiempo medio de resolución gracias a procedimientos ya validados.
- FCR:** más incidencias complejas resueltas en primer contacto por el nivel inicial, con menos escalados.

Arquitectura soberana y diseño relacional

La arquitectura seguirá el principio de **ejecución local soberana**: ni las consultas ni los manuales requerirán conectividad externa ni servicios de pago. SQL Server 2025 y Ollama convivirán en el mismo host.

Flujo operativo



Capas de la solución

Gobernanza y almacenamiento (SQL Server 2025): datos transaccionales, base de conocimiento y definiciones de seguridad.

Capa vectorial: tipo nativo `VECTOR` y cálculo de proximidad semántica dentro del motor.

IA local (Ollama): un modelo de embeddings y un modelo de lenguaje ligero, ambos en el mismo equipo.

Modelo de datos relacional y vectorial (3FN)

Entidad	Responsabilidad	Relaciones y seguridad
dbo.usuarios	Identidad de técnicos, supervisores y usuarios; rol (<code>Admin</code> , <code>TecnicoTier1</code> , <code>TecnicoTier2</code>) y departamento.	1:N con tickets y auditoria_rag. DDM sobre el correo.
dbo.sistemas	Catálogo de plataformas (ERP, CRM, SQL Server, Active Directory, Redes).	1:N con tickets y kb_articulos. Máscara parcial sobre la IP.
dbo.tickets	Incidencias con ciclo de vida (<code>Abierto</code> , <code>En Proceso</code> , <code>Resuelto</code> , <code>Cerrado</code>), severidad y fecha.	N:1 con usuarios y sistemas. Gobernada por RLS.
dbo.kb_articulos	Procedimientos aprobados: código de error, título, resolución y <code>contenido_embedding VECTOR(384)</code> .	N:1 con sistemas. Origen del contexto RAG.
dbo.auditoria_rag	Telemetría: consulta, artículos recuperados, distancia semántica y respuesta.	N:1 con usuarios; referencia a kb_articulos.

Capacidades DP-800 y estrategia de implementación

1. Espacio vectorial y búsqueda híbrida

Los manuales se vectorizarán con un modelo de embeddings local y se almacenarán en una columna del tipo nativo `VECTOR(384)`. La relevancia se ordenará mediante la distancia coseno, donde un valor menor indicará mayor similitud. La búsqueda híbrida combinará un filtro determinista por plataforma afectada con la ordenación semántica, de modo que el cálculo se limite al subconjunto pertinente.

2. Pipeline RAG local

Las dos soluciones más relevantes se inyectarán como contexto en un prompt restringido dirigido al modelo de lenguaje local. SQL Server aportará la verdad documental y el modelo redactará la solución. El prompt obligará a abstenerse si no hay documentación formal, y se aplicará un umbral de distancia mínima antes de invocar al modelo. Cada interacción quedará registrada en la tabla de auditoría para garantizar la trazabilidad.

3. Seguridad nativa en el motor

El **Dynamic Data Masking** ocultará fragmentos de correos y direcciones IP según el rol, sin alterar los datos almacenados. El **Row-Level Security** filtrará las incidencias por departamento mediante una política de seguridad basada en una función de predicado vinculada al esquema. Al aplicarse antes de la recuperación vectorial, ningún documento restringido llegará al modelo de lenguaje ni a la respuesta.

4. Optimización empírica

Se medirá una consulta de reporte masivo antes y después de crear índices filtrados y de cobertura. La evidencia consistirá en el plan de ejecución real, que mostrará la sustitución de **Table Scan** por **Index Seek**, y en las lecturas lógicas obtenidas con las estadísticas de E/S.

5. Desarrollo asistido por IA con supervisión humana

Se emplearán asistentes de código (Copilot / ChatGPT) en las fases de diseño. Se documentarán los prompts, se identificarán los errores de la IA (por ejemplo, tipos de datos obsoletos) y se validará manualmente cada cambio.

Principio rector: la seguridad y la veracidad se resolverán en la capa de datos, no en la aplicación ni en el modelo.

Plan de trabajo y gestión de riesgos

Plan de trabajo en cuatro fases

F1

Modelado.
Despliegue en SQL Server 2025 con compatibilidad 170, estructura relacional con integridad referencial y restricciones `CHECK`, y carga de un lote representativo de incidencias, sistemas y artículos.

F2

Seguridad y optimización.
Enmascaramiento dinámico de IPs y correos, política de Row-Level Security por departamento, y diagnóstico de una consulta masiva con la incorporación de índices.

F3

IA y RAG.
Configuración del modelo local de embeddings, carga de vectores, validación de la similitud semántica y construcción del puente de comunicación con el modelo de lenguaje.

F4

Documentación y validación.
Organización del repositorio, memoria técnica con evidencias y capturas de cada hito, y presentación ejecutiva para la defensa.

Análisis de riesgos técnicos

Riesgo	Impacto	Medida de mitigación
Alucinaciones del LLM	Alto	Prompt restringido al contexto de SQL Server, umbral de distancia y declaración explícita de ausencia de documentación.
Contención de memoria por cómputo local	Medio	Modelos ligeros de menos de 4.000 millones de parámetros, ejecutables en RAM estándar sin competir con el motor.
Obsolescencia documental	Medio	Revisión periódica y marcas temporales para priorizar artículos actualizados.
Acceso indebido a procedimientos restringidos	Alto	RLS en el motor: el buscador vectorial no devolverá documentos no autorizados.

Cumplimiento DP-800, entregables y valor estratégico

Matriz de cumplimiento DP-800

Bloque	Competencia	Cobertura en SysDesk AI
A	Diseño relacional	Esquema 3FN, claves, restricciones <code>CHECK</code> , vistas y procedimientos (SLA).
B	Desarrollo asistido por IA	Registro de prompts, errores de la IA y validación manual.
C	Seguridad y menor privilegio	Dynamic Data Masking y Row-Level Security.
D	Optimización	Índices filtrados/cobertura y comparación de planes de ejecución.
E-F	Vector y búsqueda híbrida	Tipo <code>VECTOR(384)</code> , distancia coseno y filtro por plataforma.
G	RAG	Contexto desde SQL Server, LLM local y abstención ante falta de documentación.

Entregables y estructura del repositorio

```
dp-800-sysdesk-ai/
├─ database/      esquema relacional, DDM, RLS e índices
├─ ai/           embeddings, búsqueda vectorial y orquestación RAG
├─ tests/        pruebas de validación de roles y rendimiento
├─ docs/         arquitectura y propuesta técnica formal
├─ presentation/ diapositivas de defensa ejecutiva
└─ README.md     guía de reproducción y despliegue paso a paso
```

- **Repositorio público en GitHub** con scripts ordenados e instrucciones de despliegue.
- **Memoria técnica en PDF** de 5 a 10 páginas con justificación, planes de ejecución y pruebas de seguridad.
- **Presentación ejecutiva** para la defensa técnica en 5 a 8 minutos.

Conclusión

SysDesk AI demostrará cómo una base de datos corporativa sobre **Microsoft SQL Server 2025** puede evolucionar hacia un sistema inteligente sin renunciar a la seguridad, la gobernanza ni la soberanía del dato. La propuesta cubrirá las competencias nucleares de DP-800 con un caso práctico, realista y de alto impacto, y constituirá una pieza sólida de portfolio en ingeniería de datos e IA.